

IFMG - Campus Ouro Preto - MG
Especialização em Inteligência Artificial
Redes Neurais e Aprendizado Profundo

Atividade Avaliativa

Docente: Prof. Dr. Agnaldo José da Rocha Reis

Aluno: Dionízio Júnio Inácio

Resolução:

Obs: Os Exercícios 3, 4, 6, 7, 8 encontram-se em seus respectivos arquivos notebook em python.

Exercício 1

Inteligência consiste na capacidade de analisar, propor e executar a resolução de problemas, passando por situações adversas para este fim, adaptando-se ao contexto e contornando possíveis imprevistos e/ou entraves no decorrer do processo.

Exercício 2

Acredito que se uma I.A. altamente abrangente (e.g., AGI) fosse implementada em um robô teríamos uma máquina capaz de se adaptar às mais diversas situações propostas, além de se comportar de forma análoga a um ser humano. Tendo em vista que a IA desenvolvida teria à sua disposição como base de dados todo o material registrado que foi vivenciado, produzido e relatado pela humanidade e a partir disso fosse capaz de aprimorar/aperfeiçoar toda a informação que julgasse como errada ou mal desenvolvida por nós. Tendo como experiência para aprendizagem as mesmas questões de vivência em sociedade, ética e morais que enfrentamos.

Porém, sem passar por um processo tão “lento” de construção cognitiva quanto o nosso. Além disso, devido a complexidade do aprendizado para este caso, o sistema descartaria tudo que julgasse desnecessário, bem como teria comportamentos que nós não temos naturalmente, pois os dilemas e impasses seriam resolvidos baseados na nossa vivência, mas não resolvidos em sua totalidade igualmente às nossas decisões.

Exercício 3 (As respostas A, B, C encontram-se no arquivo notebook 'ex3.ipynb')

D - O peso é ajustado a cada época, fazendo com que a diferença entre o erro e a saída desejada seja minimizada. Sendo assim, o número de épocas dependerá da necessidade dos ajustes dos pesos enquanto os erros não forem anulados ou o número máximo de épocas não for atingido.

E - Perceptrons são limitados quanto às suas aplicações, ficando restrito a classificações onde as amostras compõem um conjunto linearmente separável.

Exercício 4 (As respostas encontram-se no arquivo notebook 'ex4.ipynb')

Exercício 5

O projeto sugerido para o problema em questão seria composto por duas partes, conforme foi sugerido no enunciado:

Parte 1 - Módulo de Visão Computacional:

Este módulo consiste basicamente na captação das imagens. A aquisição das imagens pode ser feita utilizando algum dispositivo com câmera e sensores para o reconhecimento das flores apresentadas em tempo real. O kinect pertencente ao console Xbox possui as características que atendem a tal demanda. Além disso, este dispositivo é relativamente fácil de integrar ao hardware proposto para a classificação das imagens.

Parte 2 - Módulo de Classificação:

Integrado ao kinect será necessário a utilização de uma unidade de tratamento, processamento, alimentação de todo o sistema e classificação das imagens. Para isso, pode-se utilizar uma unidade Raspberry com alguma distribuição linux embarcada ao hardware, o sistema de reconhecimento, tratamento e classificação das imagens será totalmente em linguagem python, utilizando-se das muitas bibliotecas específicas (Numpy, scikit learn, Tensor Flow, etc.) para este fim.

As imagens geradas podem ser classificadas com o auxílio de uma rede neural convolucional (CNN - Convolutional Neural Network), a utilização desse tipo de rede é bem difundida no segmento de reconhecimento de padrões em imagens e vídeos devido a sua capacidade de aprendizagem de hierarquias de características presentes nas imagens em diferentes níveis de abstração. A principal característica desse tipo de arquitetura é a capacidade de aplicar filtros convolucionais, permitindo que a rede aprenda padrões e características relevantes em diferentes partes da entrada.

Basicamente as CNN's são compostas por 5 estruturas principais:

- Camada de convolução: camada responsável pela aplicação da técnica de convolução que utiliza filtros para a extração de características relevantes da imagem;
- Camada de Pooling: Essa camada reduz a dimensão das características identificadas priorizando apenas informações de maior relevância para a classificação;

- Camadas totalmente conectadas: Essa camada realiza a classificação final ou outras tarefas como regressão;
- Funções de ativação: Aplicadas após as etapas de convolução e pooling para introduzir não-linearidade à rede.
- Camadas de normalização: Essas camadas estabilizam o treinamento, garantem maior convergência e generalização à rede.


Abaixo encontra-se uma imagem exibindo os componentes e as funções de cada dispositivo presente no projeto proposto:



Flores à serem classificadas dispostas à frente do aparato de aquisição das imagens.



Kinect utilizado para a aquisição e mapeamento das imagens.



Raspberry PI rodando sistema baseado em linux com python (incluindo as bibliotecas necessárias) para a programação do modelo de classificação baseado em rede neural do tipo CNN.

Fonte: O autor

Exercício 6 (A resolução deste exercício encontra-se o arquivo notebook 'ex6.ipynb')

Exercício 7 (A resolução deste exercício encontra-se o arquivo notebook 'ex7.ipynb')

Exercício 8 (A resolução deste exercício encontra-se o arquivo notebook 'ex8.ipynb')

Exercício 9

Artigo 1

O artigo em questão propõe a utilização de um novo modelo de rede neural híbrida denominado AE-LTSM aplicado à indústria química. Especificamente na predição da concentração de ácido acético presente na torre de destilação fracionada no processo de produção de ácido tereftálico purificado (PTA). A solução proposta mescla duas técnicas, AE (Auto Encoder) e LSTM (Long Short-Term Memory), a primeira técnica AE consiste numa rede neural de aprendizado profundo não supervisionado a fim de reduzir a dimensionalidade dos dados de entrada, obtendo na saída apenas os dados críticos para a predição do processo. A segunda técnica utilizada, LSTM, é uma variação de RNN (Recurrent Neural Network), mais adequada para lidar com situações cuja aplicação de uma RNN tradicional teria problemas devido ao comprometimento da capacidade de aprendizagem ocasionado por desvanecimento de gradiente quando a rede utiliza backpropagation para dados com dependências de longo prazo.

Na conclusão, os proponentes do artigo mencionam que a rede tem uma alta eficácia, pois a aplicação do AE diminui a carga de dados utilizada, diminuindo também a demanda de hardware. Além disso, as particularidades da rede LSTM, porta de esquecimento, porta de entrada e porta de saída, garantem uma modelagem melhor de dados temporais não lineares e dinâmicos. Sobretudo, o modelo proposto tem uma acurácia maior que os modelos BP-LSTM e PCA-LSTM em 30% a 18% e 12%, respectivamente.

Referência:

Y. He, P. Wang, Y. Xu and Q. Zhu, "An Improved Industrial Process Soft Sensor Method Based on LSTM," *2023 IEEE 12th Data Driven Control and Learning Systems Conference (DDCLS)*, Xiangtan, China, 2023, pp. 1750-1755, doi: 10.1109/DDCLS58216.2023.10165845.

Artigo 2

A segunda publicação escolhida propõe o desenvolvimento de um soft sensor capaz de realizar medições multivariadas. Tendo como base as propriedades optoeletrônicas de um Líquido iônico à temperatura ambiente (Room Temperature Ionic Liquid - RTIL). Basicamente, o sensor consiste num tubo flexível, contendo um líquido ionizado em seu interior com um LED numa de suas extremidades e um fotodiodo na outra ponta a fim de captar a luz emitida pelo LED à partir da ponta oposta. Neste caso, são analisados os comportamentos da frequência da luz emitida pelo LED e da tensão do fotodiodo, conforme o conjunto é submetido a flexão e tração ao longo do tempo.

Integrado à estrutura do tubo, há um sistema de alimentação do LED, bem como todo aparato de hardware para amostragem, tratamento e aplicação de inteligência artificial sobre o sinal amostrado. Para fim de testes do sensor foi montada uma bancada com um motor de passo para simular a flexão e tração do conjunto. Feito isso e coletada a amostra, o sistema integrado ao sensor trata os dados e os submete a uma rede neural do tipo LSTM (Long Short-Term Memory). A rede LSTM é uma variação de RNN (Recurrent Neural Network), mais adequada para lidar com situações cuja aplicação de uma RNN tradicional teria problemas devido ao comprometimento da capacidade de aprendizagem ocasionado por desvanecimento de gradiente quando a rede utiliza backpropagation para dados com dependências de longo prazo.

No fim, o sensoramento e análise feitos de forma combinada (frequência do sinal de LED e tensão no fotodiodo) mostrou-se capaz de identificar com eficácia quando o conjunto está sendo submetido somente à tração, somente à flexão, ou a combinação dos dois movimentos, tendo grande potencial de aplicação em dispositivos wearables e robóticos.

Referência:

M. Xu, J. Ma, Q. Sun and H. Liu, "Ionic Liquid-Optoelectronics-Based Multimodal Soft Sensor," in IEEE Sensors Journal, vol. 23, no. 13, pp. 14809-14818, 1 July1, 2023, doi: 10.1109/JSEN.2023.3279527.